

第一次讨论

名字

October 27, 2016

目 录

1	线性回归	4
1.1	一元线性回归	4
1.1.1	cost function	4
1.2	多元线性回归	4
1.2.1	cost function	5
2	逻辑斯提回归	5
3	贝叶斯	6
3.1	离散型的	7
3.2	连续型的	7

摘 要

上午我们讨论了线性回归，逻辑斯提回归，贝叶斯，从公式开始推导，参数的求解，以及costfunction的应用。

keywords: 线性回归; 逻辑斯提回归; 贝叶斯; cost function

§1 线性回归

§1.1 一元线性回归

一元线性回归, 即只有一个变量, 公式的为 $Y = \beta_0 + \beta_1 X$. 现在我们的任务是要求解参数 β_0 以及 β_1 , 这里给出两种方法: 最小二乘法, 梯度下降法。

§1.1.1 cost function

一元线性回归的cost function 是:

$$J(\beta_0, \beta_1) = \frac{1}{2N} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)^2$$

最小二乘法:

分别对 J 关于 β 求导:

$$\frac{\partial J(\beta_0, \beta_1)}{\partial \beta_0} = -\frac{1}{N} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)$$

$$\frac{\partial J(\beta_0, \beta_1)}{\partial \beta_1} = -\frac{1}{N} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i) x_i$$

分别令上面两个式子为0, 便可求得参数 β_0 以及 β_1

梯度下降法:

分别对 β_0 以及 β_1 做偏导后, 再利用梯度下降法来对参数进行更新处理, 直到 $|J(\beta_0, \beta_1)_k - J(\beta_0, \beta_1)_{k+1}| < \epsilon$ 小于某个给定的阈值。更新公式如下:

$$\beta_0 = \beta_0 - \alpha \frac{\partial J(\beta_0, \beta_1)}{\partial \beta_0} = \beta_0 - \alpha \frac{1}{N} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)$$

$$\beta_1 = \beta_1 - \alpha \frac{\partial J(\beta_0, \beta_1)}{\partial \beta_1} = \beta_1 - \alpha \frac{1}{N} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i) x_i$$

更新一次后, 带入 $J(\beta_0, \beta_1)$ 中, 利用 $|J(\beta_0, \beta_1)_k - J(\beta_0, \beta_1)_{k+1}| < \epsilon$

§1.2 多元线性回归

公式的形式为: $Y = \beta_0 + \beta_1 X_1 + \dots + \beta_m X_m$, 这里设置 $X_0 = 1$, 于是公式改为: $Y = \beta_0 X_0 + \beta_1 X_1 + \dots + \beta_m X_m$, 将公式整合到一起写, 设置 $\beta = (\beta_0, \beta_1, \dots, \beta(m))$, 得到

$$Y = \beta^T X$$

§1.2.1 cost function

$$J(\beta) = \frac{1}{2m} \sum_{i=0}^m (y_i - \beta x_i)^2$$

接下来是对 $J(\beta)$ 的每个参数 β 求偏导，需要注意的是 $i = 0$ 时的情形。

对于 $i = 0$ 时，

$$\frac{\partial J(\beta)}{\partial \beta_0} = \beta_0 - \alpha \frac{\partial J(\beta)}{\partial \beta_0} = \beta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (y_i - \beta x_i)$$

对于 $i > 0$ 时，

$$\frac{\partial J(\beta)}{\partial \beta_i} = \beta_i - \alpha \frac{\partial J(\beta)}{\partial \beta_i} = \beta_i - \alpha \frac{1}{m} \sum_{i=1}^m (y_i - \beta x_i) x_i$$

§2 逻辑斯提回归

逻辑斯提回归是将回归的思想用于分类中。二分类中，有 A 和 B 两类。我们在使用概率时，如果 $p > 0.5$ ，会将结果判为 A 类；如果 $p < 0.5$ ，会将结果判为 B 类。




Fig. 1. 图解1

问题：如何引入一个平滑的函数来刻画这个过程呢？而且这个函数必须是递增的，取值范围为0到1之间。

联想到函数 $\frac{1}{1+e^{-x}}$ 满足这个性质，图如下：




Fig. 2. 图解2

于是，得到 p 的函数形式， $p = \frac{1}{1+e^{-x}}$ ，这里的 x 为线性的变化，能否引入非线性的呢？当然可以，这里我们将非线性的引入，式子变为：

$$p = \frac{1}{1+e^{-a}} = \frac{1}{1+e^{-\beta^T x}}$$

对于分类问题，响应变量 y 是离散，没法使用 **cost function** 来表示。回忆起我们在求解概率问题的参数时采用极大似然法来解决。同样，我们这里也采用这个方法。

$$Y = A, p = \frac{1}{1+e^{-\beta^T x}}$$

$$Y = B, p = 1 - \frac{1}{1+e^{-\beta^T x}} = \frac{e^{-\beta^T x}}{1+e^{-\beta^T x}}$$

那么有：

$$J = -\frac{1}{m} \left[\sum_{i=0}^m y_i \log(p) + (1 - y_i) \log(1 - p) \right]$$

$$J = -\frac{1}{m} \left[\sum_{i=0}^m y_i \log\left(\frac{1}{1+e^{-\beta^T x}}\right) + (1 - y_i) \log\left(\frac{e^{-\beta^T x}}{1+e^{-\beta^T x}}\right) \right]$$

化简后为：

$$J = -\frac{1}{m} \left[\sum_{i=0}^m y_i \beta^T x - \log(1 + e^{\beta^T x}) \right]$$

§3 贝叶斯

贝叶斯的使用假设是：数据是独立同分布的。

将贝叶斯用于分类中，以概率为判断准则，谁的概率值大，结果就属于对应的

类别。

公式:

$$p(Y|X) = \frac{p(Y)p(X|Y)}{p(X)}$$

这里的 $p(X)$ 、 $p(Y)$ 属于先验信息。 $p(X|Y)$ 属于条件概率。通过这三个量来求后验概率，从而达到分类的效果。又由于对某个数据，需要将它分类，在所有类的判别时，它的概率是不变的，即分母不变。公式还可以改为:

$$p = p(Y)p(X|Y) = p(Y)p(x^1, x^2, \dots, x^m | Y = c_k) = p(Y) \prod_{i=1}^m p(x^i | Y = c_i)$$

§3.1 离散型的

上面式子的 $p(X)$ 、 $p(Y)$ 、 $p(X|Y)$ 是可以直接计算出来，从而求出后验信息 $p(Y|X)$ 。

§3.2 连续型的

根据离散型的可知，得到连续型的形式为:

$$p = p(Y)f$$

这里的 f 为数据 x 所服从分布的密度函数。这个在LAD和QDA中将使用到。